

# *Cerberus en Pathologie Computationnelle:*

Revue, Optimisation et Applications de l'Apprentissage par Transfert.

*Un projet basé sur article: "One model is all you need: Multi-task learning enables simultaneous histology image segmentation and classification"*

Présenté par: Oussama RCHAKI

Supervisé par: Pr. Vannary MEAS-YEDID HARDY

Sorbonne Université

M2 IMA (Traitement avancé d'image et vision)

February 3, 2025

1. Pathologie Computationnelle : Objectifs et Défis
2. Apprentissage Multi-Tâches pour le Transfer learning
3. Cerberus: Architecture et Entraînement
4. Cerberus pour l'Apprentissage par Transfert: Applications
5. Conclusion

## Pathologie Computationnelle: définition

La pathologie computationnelle (CPath) est un domaine émergent et transformateur qui exploite l'apprentissage automatique et les techniques computationnelles avancées pour analyser les données pathologiques, dans le but d'améliorer la précision diagnostique, le pronostic des maladies et la planification des traitements.

CPath vise à atteindre plusieurs **objectifs** clés :

- Amélioration de la précision diagnostique et de la reproductibilité
- Médecine personnalisée et perspectives pronostiques
- Intégration avec des données multimodales pour une analyse complète
- Facilitation de la collaboration multidisciplinaire

Cependant, la CPath doit surmonter plusieurs **défis** majeurs pour atteindre ses objectifs :

- Hétérogénéité des données et généralisabilité
- Contraintes liées à l'annotation et à l'étiquetage des données
- Problématiques réglementaires et éthiques
- Interprétabilité et transparence : besoin de modèles explicables

# Apprentissage Multi-Tâches pour l'Apprentissage par Transfert

## Apprentissage Multi-Tâches: définition

L'Apprentissage Multi-Tâches (MTL) est une approche d'apprentissage automatique où un modèle est entraîné à réaliser plusieurs tâches simultanément, en exploitant des représentations partagées pour apprendre de manière plus efficace et efficiente.




Illustration de l'Apprentissage Multi-Tâches, [Caruana, (1997)]

## l'Apprentissage par Transfert: définition

L'apprentissage par transfert est une technique d'apprentissage automatique où un modèle entraîné sur une tâche est réutilisé ou affiné pour une autre tâche connexe, en exploitant les connaissances du domaine source afin d'améliorer les performances dans le domaine cible.

L'apprentissage multi-tâches (MTL) croise l'apprentissage par transfert en permettant le partage des connaissances entre les tâches afin d'améliorer la généralisation du modèle.

# Cerberus: Architecture et Entraînement

## Cerberus: définition

Un réseau de neurones entièrement convolutionnel conçu pour l'Apprentissage Multi-Tâches (MTL), capable de gérer plusieurs tâches histologiques (segmentation, classification) au sein d'un cadre unifié.

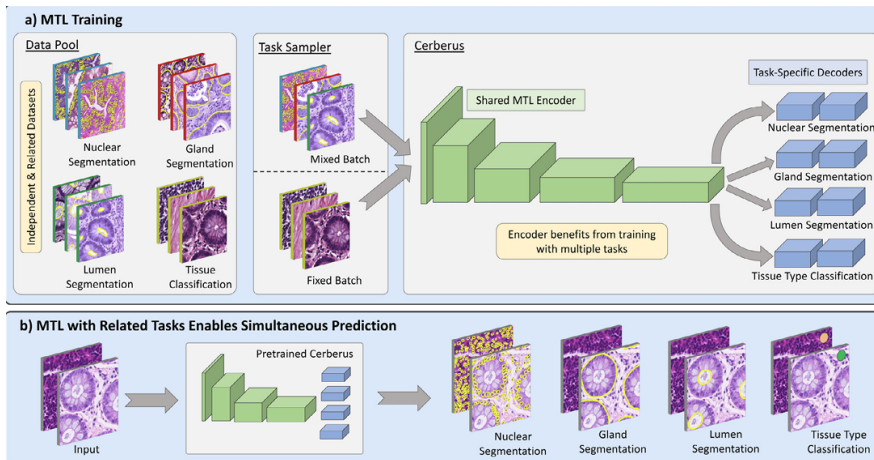




## Architecture

- **Encodeur Partagé:**
  - ResNet34 pour l'extraction de caractéristiques et la facilitation de l'apprentissage par transfert.
  - Apprend une représentation générale bénéfique pour toutes les tâches.
- **Décodeurs Spécifiques aux Tâches:**
  - **Segmentation** : Décodeur de type U-Net avec upsampling, connexions résiduelles et convolutions  $3 \times 3$ .
  - **Classification** : Pooling global moyen, suivi de 2 couches entièrement connectées (256 dimensions, Dropout 0.3).


# Cerberus: Architecture et Entraînement



Entraînement de Cerberus, [Graham, S. (2023)]

# Cerberus pour l'Apprentissage par Transfert: Applications

Pour les applications de l'apprentissage par transfert, nous utilisons l'ensemble de données issu de l'article de [Shi et al., (2023)].



(a) Normal (b) Polyp (c) High-grade Intraepithelial Neoplasia (d) Low-grade Intraepithelial Neoplasia (e) Adenocarcinoma (f) Serrated adenoma, [Shi et al., (2023)]

# Cerberus pour l'Apprentissage par Transfert: Applications

Les méthodes suivantes d'augmentation des données ont été appliquées afin d'améliorer l'ensemble d'entraînement :


- **Transformation Élastique** : Déforme l'image à l'aide de déformations élastiques aléatoires (ex. : étirement, distorsion).
- **Luminosité/Contraste Aléatoires** : Ajuste la luminosité et le contraste de manière aléatoire pour simuler des variations d'éclairage.
- **Rotation** : Fait pivoter l'image aléatoirement dans une plage de  $\pm 35^\circ$ .
- **Symétrie Horizontale** : Effectue un retournement horizontal avec une probabilité de 50%.
- **Symétrie Verticale** : Effectue un retournement vertical avec une probabilité de 10%.
- **Flou Gaussien** : Applique un flou gaussien avec une taille de noyau comprise entre 3 et 7 afin de simuler une situation de flou.

# Cerberus pour l'Apprentissage par Transfert: Applications

| Fine tuning à partir de: | <b>Layer 1</b> | <b>Layer 2</b> | <b>Layer 3</b> | <b>Layer 4</b> | <b>SVM</b> |
|--------------------------|----------------|----------------|----------------|----------------|------------|
| Précision                | 85.2%          | 82.5%          | 80.3%          | 79.4%          | 59.1%      |

Résultats de la classification par l'apprentissage par transfert

# Cerberus pour l'Apprentissage par Transfert: Applications



# Cerberus pour l'Apprentissage par Transfert: Applications

## Performance Index Formulas For Segmentation:

- **Dice Ratio (Dice):**

$$\text{Dice} = \frac{2 \cdot |A \cap B|}{|A| + |B|}$$

où  $A$  est l'ensemble prédit et  $B$  est l'ensemble de vérité terrain.

- **Jaccard Index (IoU):**

$$\text{Jaccard} = \frac{|A \cap B|}{|A \cup B|}$$

- **Conformity Coefficient (Confm Index):**

$$\text{ConfmIndex} = \begin{cases} 1 - \frac{\theta_{AE}}{\theta_{TP}}, & \text{if } \theta_{TP} > 0, \\ \text{Failure}, & \text{if } \theta_{TP} = 0, \end{cases}$$

où  $\theta_{AE} = \theta_{FP} + \theta_{FN}$  (toutes les erreurs) et  $\theta_{TP}$  est le nombre de pixels correctement classifiés.

- **Precision:**

$$\text{Precision} = \frac{\text{True Positives (TP)}}{\text{TP} + \text{False Positives (FP)}}$$

- **Recall:**

$$\text{Recall} = \frac{\text{True Positives (TP)}}{\text{TP} + \text{False Negatives (FN)}}$$


# Cerberus pour l'Apprentissage par Transfert: Applications

| Category         | Model         | DiceRatio    | JaccardIndex | CC           | Precision    | Recall       |
|------------------|---------------|--------------|--------------|--------------|--------------|--------------|
| Normal           | U-Net         | 0.411        | 0.263        | -2.199       | 0.586        | 0.328        |
|                  | Seg-Net       | 0.777        | 0.684        | -0.607       | 0.895        | 0.758        |
|                  | MedT          | 0.676        | 0.562        | -0.615       | 0.874        | 0.610        |
|                  | Cerberus (TL) | <b>0.967</b> | <b>0.937</b> | <b>0.933</b> | <b>0.972</b> | <b>0.963</b> |
| Polyp            | U-Net         | 0.965        | 0.308        | -1.514       | 0.496        | 0.470        |
|                  | Seg-Net       | 0.937        | 0.886        | 0.858        | 0.916        | <b>0.965</b> |
|                  | MedT          | 0.771        | 0.648        | 0.336        | 0.687        | 0.920        |
|                  | Cerberus (TL) | <b>0.967</b> | <b>0.937</b> | <b>0.933</b> | <b>0.971</b> | 0.963        |
| High-grade IN    | U-Net         | 0.895        | 0.816        | 0.747        | 0.847        | <b>0.961</b> |
|                  | Seg-Net       | 0.894        | 0.812        | 0.757        | 0.881        | 0.913        |
|                  | MedT          | 0.824        | 0.707        | 0.556        | 0.740        | 0.958        |
|                  | Cerberus (TL) | <b>0.936</b> | <b>0.880</b> | <b>0.864</b> | <b>0.933</b> | 0.940        |
| Low-grade IN     | U-Net         | 0.911        | 0.849        | 0.773        | 0.879        | 0.953        |
|                  | Seg-Net       | 0.924        | 0.864        | 0.826        | 0.883        | <b>0.977</b> |
|                  | MedT          | 0.889        | 0.808        | 0.718        | 0.876        | 0.916        |
|                  | Cerberus (TL) | <b>0.964</b> | <b>0.932</b> | <b>0.927</b> | <b>0.970</b> | 0.959        |
| Adenocarcinoma   | U-Net         | 0.887        | 0.808        | 0.718        | 0.850        | 0.950        |
|                  | Seg-Net       | 0.865        | 0.775        | 0.646        | 0.792        | <b>0.977</b> |
|                  | MedT          | 0.735        | 0.595        | 0.197        | 0.662        | 0.864        |
|                  | Cerberus (TL) | <b>0.928</b> | <b>0.865</b> | <b>0.845</b> | <b>0.924</b> | 0.931        |
| Serrated adenoma | U-Net         | <b>0.938</b> | <b>0.886</b> | 0.865        | 0.899        | <b>0.980</b> |
|                  | Seg-Net       | 0.907        | 0.832        | 0.794        | 0.859        | 0.963        |
|                  | MedT          | 0.670        | 0.509        | -0.043       | 0.896        | 0.544        |
|                  | Cerberus (TL) | 0.937        | 0.882        | <b>0.867</b> | <b>0.965</b> | 0.911        |

Résultats de la segmentation par l'apprentissage par transfert.



# Cerberus pour l'Apprentissage par Transfert: Applications



Normal




ground truth



prediction

# Cerberus pour l'Apprentissage par Transfert: Applications



Polyp




ground truth



prediction

# Cerberus pour l'Apprentissage par Transfert: Applications



Low-grade IN




ground truth



prediction

# Cerberus pour l'Apprentissage par Transfert: Applications



Serrated adenoma



ground truth



prediction

- **Cerberus en tant que modèle MTL** : Cerberus a démontré des résultats très prometteurs, mettant en avant le potentiel de l'apprentissage multi-tâches (MTL) pour améliorer les solutions d'apprentissage par transfert et optimiser les performances sur plusieurs tâches simultanément.
- **Le besoin d'un jeu de données à grande échelle** : Il existe un besoin crucial d'un référentiel de données complet et collaboratif, similaire à ImageNet, mais spécifiquement conçu pour les images histologiques. Un tel jeu de données permettrait :
  - L'entraînement de modèles MTL plus grands et plus performants, comme Cerberus.
  - Une meilleure collaboration et une plus grande innovation au sein de la communauté de recherche en histologie.
- **Cerberus pour l'annotation automatique** : Cerberus pourrait constituer une excellente solution pour annoter automatiquement les données histologiques, permettant ainsi de gagner un temps considérable et de réduire les ressources nécessaires à l'entraînement des futurs modèles.

- Shi, L., Li, X., Hu, W., et al. (2023). *EBHI-Seg: A novel enteroscope biopsy histopathological hematoxylin and eosin image dataset for image segmentation tasks*. *Frontiers in Medicine*, 10, Article 1114673. <https://doi.org/10.3389/fmed.2023.1114673>
- Graham, S., Vu, Q. D., Jahanifar, M., Raza, S. E. A., Minhas, F., Snead, D., Rajpoot, N. (2022). One model is all you need: Multi-task learning enables simultaneous histology image segmentation and classification. *Medical Image Analysis*, 82, 102613.
- Caruana, R. "Multitask Learning." *Machine Learning*, vol. 28, no. 1, pp. 41-75, 1997.